

【主題名稱】 智聊小精靈 (Gemini Smart Assistant)

基於 Google Gemini 模型之繁體中文生活對話助理專案計畫書

專案摘要： 本專案實作一套結合 Python Flask、LINE Messaging API v3 與 Google Gemini 大型語言模型的智慧對話機器人，具備繁中手機排版最佳化、長度控制、標點符號安全截斷、貼圖已讀不回與四重模型自動降級備援機制，達成 100% 零主機成本運行。

機器人命名 (Topic Title)

智聊小精靈 (Gemini Smart Bot)

開源儲存庫

github.com/41154B003Sam/line-bot

版本狀態

Release v1.0 (Production Verified)

核心技術棧

Flask 3.1, LINE SDK v3, Google GenAI,
Cloudflare

1. 機器人命名與主題 (Topic Title)

正式名稱：智聊小精靈 (Gemini Smart Bot)

命名意涵：以「智慧聊聊」為核心概念，化身為常駐在每位使用者 LINE 聊天室裡的輕巧小精靈。免除複雜 App 下載，透過最熟悉的通訊軟體即可隨時進行繁體中文日常問答、生活規劃與靈感啟發。

2. 目標客群與欲解決問題 (Target Audience & Purpose)

目標客群 (Target Audience)

- LINE 高頻度日常使用者**：上班族、在學學生、自由工作者與家庭生活者。
- 需要即時靈感與生活解答者**：不想打開厚重視窗或搜尋引擎慢慢翻找網頁，希望輸入一句話即可得到精準解答的人群。
- 追求極簡溝通介面者**：習慣手機直覺打字互動，排斥被無關廣告與繁複功能干擾的使用者。

欲解決之痛點 (Problem Solved)

- 跨 App 查詢之操作負擔**：不再需要切換至外網或付費 AI 平台，在日常聊天室即可 24 小時免費提問。
- 打破傳統 Bot 死板限制**：告別傳統 Echo 機器人只會覆誦或依賴關鍵字匹配的生硬體驗。
- 手機端排版適配問題**：傳統 AI 容易輸出過長字串或在手機上殘留不支援的 Markdown 粗體星號 (**)，本系統專注於手機閱讀體驗之優化。

3. 本次實作核心功能 (Core Function)

第一版 (v1.0) 聚焦實作之關鍵核心為：「繁中語意問答與排版收斂引擎」，其包含以下五大核心模組：

模組名稱	技術規格與實作機制
Gemini 模型串接	使用官方 google-genai SDK，注入繁體中文在地化 System Prompt，設定親切幽默之專屬人設。
四重模型自動降級 (Fallback)	依序嘗試 gemini-flash-latest → gemini-3.8-flash → gemini-3.5-flash → gemini-flash-lite，抵禦 503 限流。
輸出長度嚴格控制	限制回覆於 250 ~ 450 字之間（最長不超過 500 字），設定 max_output_tokens=2048 防止 token 不足半句斷頭。
標點安全截斷演算法	若模型偶然超過 500 字，演算法會在倒數最近的標點（。、！、？、換行）安全收尾，絕不留下半句殘詞。
Markdown 星號清洗	自動過濾 LINE 不支援的雙星號 ** 粗體語法，轉為親切自然之條列與 Emoji 排版。

4. 對話範例展示 (Dialogue Examples)

以下展示機器人於「正常使用情境」與「輸入不完整 / 模糊情境」下之實際對話反應：

4.1 組一：正常使用情境 (Normal Usage Scenario)

 使用者輸入：

「我想在週末安排台北一日遊，請推薦 3 個搭捷運能到的景點和美食！」

 智聊小精靈回覆：

嗨！沒問題，為你精選 3 個搭捷運就能輕鬆抵達的台北一日遊好去處 🚇 ✨

1. 中山站赤峰街：漫步文青巷弄小店與老宅咖啡廳，推薦品嚐排隊甜點戚風蛋糕 🍰
2. 大安森林公園站：享受都市森林綠意，野餐放鬆，還能順道漫步永康街吃牛肉麵 🍝
3. 淡水站金色水岸：傍晚漫步淡水河畔看浪漫夕陽，必吃現炸魚酥與阿給小吃 🐟

這條路線交通非常順暢，很適合週末放慢步調散步放鬆喔！祝你有個愉快充實的週末～ 😊

4.2 組二：輸入不完整 / 模糊情境 (Incomplete / Ambiguous Scenario)

 使用者輸入：

「推薦」

 智聊小精靈回覆：

哈囉！看到你發送了簡短的關鍵字，我猜你可能是想尋找推薦？ 😊

為了提供最符合你需求的精準建議，可以再多告訴我一點線索嗎：

- 🍽️ 美食晚餐推薦：想找平價小吃、精緻火鍋、日式料理還是聚餐餐廳？地點在哪個區域？
- 🎬 休閒娛樂推薦：想看熱門電影、推薦書籍、還是週末旅遊踏青景點？
- 📱 科技生活推薦：想了解 3C 產品還是實用 App 工具？

只要隨時補充你的預算或地點，我就能馬上為你量身推薦囉！隨時等你的訊息～ ✨

5. AI 輔助開發方式與範疇 (AI Assistance Methods)

在本次專案的全生命週期中，AI 深度介入輔助完成以下四大維度任務：

程式撰寫 (Programming)

- 建構 Flask 3.1 伺服器與 LINE SDK v3 框架。
- 實作 Google GenAI 客戶端呼叫與 Token 管理邏輯。

除錯與相容性 (Debugging)

- 定位並排除 Windows CP950 終端列印 Emoji 引發的崩潰例外。
- 捕獲免費版 Gemini 503 尖峰限流並架構 Try-Catch 降級佇列。

- 編寫 Markdown 星號清洗與標點安全截斷演算法。

- 修正 LINE Webhook 之 HMAC-SHA256 簽章比對驗證。



簡報產出 (Presentations)

- 規劃結構完整之 16:9 投影片內容。
- 編寫現代深色對比卡片視覺 CSS，以無頭瀏覽器產出 PDF。



網頁與 UX (Web Pages)

- 產製正式 A4 規格計畫書 HTML 排版。
- 優化行動裝置聊天排版，以 Emoji 與段落取代生硬符號。

6. 測試計畫與驗證情境 (Testing Plan)

情境編號	測試情境描繪	輸入操作	預期結果
情境一	正常對話與格式驗證測試	傳送文字：「請用繁體中文解釋什麼是機器學習？」	成功解析 Webhook，產出 250~450 字繁中回答，無 ** 星號，句尾完整以句號結束，手機正常接收。
情境二	貼圖與純 Emoji 過濾測試	聊天室發送貼圖或單一 Emoji「🌈」	後台日誌正常記錄 StickerMessageContent，不呼叫 Reply API (已讀不回)，節省額度且無報錯。
情境三	尖峰流量模型降級備援測試	模擬主模型 gemini-flash-latest 回傳 503 繁忙	後台自動降級至 gemini-3.8-flash 備援，正常生成文字並回傳，使用者端完全無感。

7. 目前進度、實測結果與未完成部分檢討

7.1 目前進度與實測成果 (Current Progress & Test Results)

- 端點健康度：本地與 Cloudflare 穿透端點 /health 回傳 HTTP 200 JSON，金鑰布林值正常且無外洩。
- Webhook 驗證：LINE Developers 後台 Verify 測試通過。
- 對話實測：手機端文字訊息成功觸發 Gemini 生成，排版符合無粗體星號與字數要求。
- 極端測試驗證：高頻測試下曾遭遇 Gemini 免費每週配額限制，證實了多模型備援與錯誤訊息回覆機制的健壯性。

7.2 第一版未完成部分與待改善問題 (Unfinished Parts & Improvement Issues)

為追求卓越工程品質，本報告誠實列出 v1.0 尚未涵蓋之項目與下一階段改善規劃：

- #### 1. 缺乏多輪上下文記憶 (Stateless)

現狀：目前問答皆為單輪獨立運作，機器人無法記憶上一個問題。例如問「推薦台北景點」，緊接著問「那邊有什麼好吃的？」，Bot 無法將兩者關聯。

改善方向：於 v2.0 引進 Redis 或 SQLite 記錄使用者最近 3~5 輪 Session 歷史。
- #### 2. 本地主機依賴與連線中斷風險

現狀：目前依賴本地開發機運行 Flask 與 Cloudflare 臨時隧道，一旦電腦關機或進入休眠，機器人即離線無法回覆。

改善方向：於 v2.0 完成 Docker 容器化封裝，部署至 Google Cloud Run 或 Render 雲端平台。
- #### 3. 缺少 LINE 圖文選單 (Rich Menu)
- #### 4. 尚未支援多模態圖片識別

現狀：聊天室底部目前為空白輸入框，缺乏直覺的功能按鈕引導，初次使用者需自行揣摩可發問內容。

改善方向：設計六宮格圖文選單，提供「日常閒聊」、「旅遊推薦」、「工作靈感」等快捷按鈕。

現狀：使用者傳送照片時會被忽略，尚未串接 Gemini Vision 進行影像分析。

改善方向：加入 `ImageMessageContent` 處理器，支援上傳照片進行 OCR 或內容辨識。